

Relatório de Projeto

SkyNET - I2A2

Processamento Fiscal Inteligente



Visit our page!



Este documento detalha o desenvolvimento e a arquitetura da plataforma SkyNET-I2A2, uma solução de Agentes de IA concebida para endereçar os desafios críticos da gestão fiscal no Brasil, transformando um centro de custo operacional em um ativo de inteligência estratégica.

Grupo: SkyNET

Integrantes do Grupo (em ordem alfabética):

- Alberto Côrtes - cortes.albert06@gmail.com
- Ernani Fantinatti (Líder do Grupo) - ernanif@fantinatti.com
- Fábio Rhein - fabiorhein@gmail.com
- Luiz Garcia - duduluiz23@gmail.com

1. Descrição do Tema Escolhido (O que foi feito)

O grupo desenvolveu uma plataforma *end-to-end* que automatiza o ciclo completo de processamento de documentos fiscais brasileiros. A solução não apenas executa tarefas, mas orquestra um fluxo de trabalho financeiro-fiscal completo:

- **Ingestão e Captura (O "Novo Malote Digital"):** Recebimento e digitalização de documentos em múltiplos formatos (XML, PDF e imagens), eliminando a entrada manual de dados.
- **Extração e Estruturação (Validação de "Contas a Pagar"):** Uso de OCR (Tesseract/Poppler) e parsers XML para extrair e normalizar 100% dos dados, preparando-os para o lançamento contábil.
- **Validação Fiscal (A "Primeira Linha de Defesa" do Compliance):** Aplicação automática de regras de negócio para validar a consistência de impostos (ICMS, IPI, PIS/COFINS) e totais, bloqueando inconsistências *antes* que elas contaminem o ERP.

- **Armazenamento e Governança (Trilha de Auditoria):** Persistência unificada em um banco de dados PostgreSQL, garantindo um histórico imutável e 100% auditável.
- **Análise Estratégica (O "BI Fiscal"):** Um assistente conversacional (Chat IA) que utiliza RAG (*Retrieval-Augmented Generation*) para permitir que a equipe financeira faça consultas em linguagem natural sobre o acervo, transformando o passivo fiscal em um ativo de dados.

O usuário deixa de ser um digitador e passa a ser um gestor, fazendo o *upload* de lotes de documentos e, em segundos, consultando um agente de IA para obter *insights* e resumos gerenciais.

Imagen 01: Front page da ferramenta.

Total de Arquivos	Processados com Sucesso	Falhas
4	4 (100.0%)	0 (0.0%)

Imagen 02: Importação em lote de documentos.

Tipo	Número	Emitente	CNPJ	Valor Total	Itens	Erros	Data	Ações
NFe	000.000.001	N/A	99.999.090/9102-70	R\$ 20.000.000,00	2	6	2025-10-30 12:16:26	<button>Ver Detalhes</button>
NFe	2.538	N/A	34.208.928/0001-88	R\$ 356,07	7	13	2025-10-30 12:16:17	<button>Ver Detalhes</button>
NFe	SEM_NUMERO	N/A	N/A	R\$ 0,00	0	7	2025-10-30 12:16:16	<button>Ver Detalhes</button>
NFe	SEM_NUMERO	N/A	N/A	R\$ 0,00	0	7	2025-10-30 12:16:15	<button>Ver Detalhes</button>
CTe	670031	VIACAO AGUIA BRANCA S/A	27486182000109	R\$ 154,47	0	1	2025-10-30 12:15:36	<button>Ver Detalhes</button>
CTe	SEM_NUMERO	Empresa emissora	None	R\$ 0,00	0	4	2025-10-30 12:15:36	<button>Ver Detalhes</button>
CTe	670031	VIACAO AGUIA BRANCA S/A	27486182000109	R\$ 154,47	0	1	2025-10-30 12:15:36	<button>Ver Detalhes</button>
CTe	SEM_NUMERO	Empresa emissora	None	R\$ 0,00	0	4	2025-10-30 12:15:36	<button>Ver Detalhes</button>
NFCe	SEM_NUMERO	None	None	R\$ 0,00	1	11	2025-10-30 12:15:36	<button>Ver Detalhes</button>

Imagen 03: Histórico de documentos importados com opção de filtragem.

Assistente IA para Análise de Documentos Fiscais

Conversa

Esta é uma nova sessão. Faça sua primeira pergunta!

Fiz algumas importações de documentos fiscais no dia de hoje. Pode me trazer um resumo dessas notas fiscais?

Pensando...

Compreendo que você precisa de um resumo das notas fiscais importadas hoje.

Análise:

- Total de documentos: 43
- Valor total dos documentos: R\$ 40.001.763,23
- Tipos de documentos:

Digite sua pergunta...

Imagen 04: Área de Chat-IA Inteligente.

2. Público-Alvo (Quem se beneficia da solução)

A solução foi projetada para gerar valor em diferentes níveis da organização financeira:

- Analistas Fiscais e Contábeis (Usuários Operacionais):** São os beneficiários diretos da automação. O foco de seu trabalho muda da digitação e verificação manual (baixo valor agregado) para a análise de exceções e planejamento (alto valor agregado).
- Gestores Financeiros e Controllers (Usuários Táticos):** Utilizam a plataforma para garantir a acuracidade do fechamento mensal, acelerar a apuração de impostos, gerar provisões fiscais mais precisas e obter dados consolidados para o planejamento tributário.
- C-Level (CFOs, VPs de Finanças e Jurídico) (Usuários Estratégicos):** Focados no resultado. Para eles, a plataforma entrega três valores principais: redução de

custos operacionais (OPEX), mitigação de risco de autuações fiscais (passivo contingente) e inteligência de negócio para tomada de decisão.

3. Justificativa do Tema Escolhido (O Valor de Negócio e o ROI)

A gestão fiscal no Brasil é um desafio notório, caracterizado por problemas que representam custos financeiros diretos e indiretos. A ferramenta ataca estes problemas centrais:

1. **Custo Operacional (OPEX) e Ineficiência:** Empresas alocam milhares de *horas-homem* para processar manualmente documentos (NFe, CTe, etc.). Esse custo é agravado pela variedade de formatos (XML, PDF, imagem), exigindo esforço manual dobrado.
2. **Risco de Compliance e Custo de Oportunidade:** O processamento manual é um passivo financeiro direto. Erros de digitação ou validação de impostos resultam em pagamentos indevidos (afetando o caixa) ou, pior, em recolhimento a menor, gerando autuações fiscais, multas e juros.
3. **Dados Fiscais como Ativo Morto:** O histórico de documentos fiscais é, na maioria das empresas, um "cemitério de dados". É um repositório valioso que raramente é usado para *insights* estratégicos, representando um custo de armazenamento sem retorno.

O valor agregado do sistema desenvolvido pelo grupo é transformar esse cenário de reativo para proativo, gerando um **ROI claro**:

- **Redução de Custo (OPEX) e Ganho de Produtividade:** A plataforma libera a equipe financeira de tarefas de baixo valor agregado. O tempo de processamento cai de horas para segundos, permitindo que o analista fiscal foque em **análise de créditos tributários**, otimização de rotas logísticas (via CTe) ou negociação com fornecedores (via NFe), em vez de digitação.
- **Mitigação de Risco e Custo de Compliance:** A validação automática reduz drasticamente o **passivo fiscal contingente** associado a erros humanos. A plataforma cria uma **trilha de auditoria** centralizada e instantânea, facilitando auditorias externas (Big4) e internas, e reduzindo custos com consultorias de remediação.
- **Transformação do Fiscal em Business Intelligence (BI):** O Chat IA com RAG desbloqueia o valor dos dados. Um gestor financeiro pode perguntar: "Qual foi nosso gasto total com ICMS-ST de fornecedores de SP no último trimestre?", "Quais fornecedores sistematicamente geram mais créditos de IPI?" ou "Qual a nossa provisão de PIS/COFINS para o próximo fechamento?". A plataforma entrega inteligência de negócio, e não apenas conformidade.

4. Detalhamento do que Foi Desenvolvido (As Ferramentas de Ganhos)

A solução é uma aplicação robusta que atua como uma extensão da equipe financeira:

- Importador de Documentos (Garantia de Integridade de Dados):
O usuário pode processar lotes de arquivos (XML, PDF, JPG, PNG) de uma só vez. O sistema aplica o parser XML ou o pipeline de OCR (Tesseract + Poppler) e, crucialmente, normaliza dados críticos (como formatos numéricos 1.234,56 e datas

DD/MM/YYYY). Isso garante a integridade dos dados antes que eles entrem no ERP, evitando erros no razão contábil.

- Guardião de Compliance (Validador Fiscal):
Após a extração, um agente de validação confere automaticamente a integridade dos dados: checagens de CNPJ/CPF e cálculos de impostos (ICMS, ICMS-ST, IPI, PIS/COFINS). Ele atua como uma primeira linha de defesa; se inconsistências são encontradas, elas são sinalizadas antes do lançamento contábil, evitando a contaminação da base de dados e o retrabalho no fechamento.
- O Controller Assistente (Chat IA com RAG):
Esta é a funcionalidade central de IA, que democratiza o acesso à informação fiscal.
 - **Exemplo de Uso:** Um gestor solicita um resumo das importações do dia. O agente de IA consulta o banco de dados, analisa os 43 documentos encontrados e retorna um sumário gerencial, agrupado por tipo (NFe, CTe) e por CNPJ do emissor. Isso é um relatório de fechamento diário em segundos.
 - **Exemplo de RAG:** O usuário pede para detalhar as notas de um CNPJ específico. O agente comprehende a entidade "CNPJ", executa uma busca filtrada e retorna a lista precisa, uma tarefa que manualmente poderia levar horas de busca em pastas ou no portal da NFe.
 - **Memória Conversacional:** O sistema armazena respostas anteriores, permitindo que o sistema reproveite análises e aprenda com as interações, garantindo consistência e acelerando respostas futuras.

5. Elementos Adicionais: Arquitetura de Custo Eficiente e Viabilidade de TCO

O diferencial do projeto é o foco no **ROI** da solução. O grupo identificou que o custo de APIs de LLMs (Gemini, OpenAI) seria proibitivo em alto volume. Para mitigar isso, foi implementada uma arquitetura híbrida que garante um **Custo Total de Propriedade (TCO)** baixo e previsível, tornando o *business case* da plataforma viável.

Diagrama de Fluxo da Solução:

(O fluxo demonstra a separação clara entre a interface, os serviços de backend e o banco de dados, que atua como a "memória" do sistema.)



Estratégias de Otimização de Custo (Foco no TCO):

O grupo implementou três estratégias para reduzir o consumo de tokens e o custo de API, garantindo a viabilidade econômica:

Estratégia	Descrição da Implementação	Impacto no Custo (Benefício Financeiro)
1. Pré-Processamento Inteligente	OCR e parsers XML extraem e estruturam os dados antes de enviá-los ao LLM.	Reduz drasticamente os <i>tokens</i> de entrada (custo de <i>input</i>). O LLM não precisa "ler" o documento bruto, apenas os dados já limpos.
2. Arquitetura RAG	O banco de dados (PostgreSQL + pgvector) fornece contexto preciso e conciso ao LLM.	Evita <i>prompts</i> longos e caros. O LLM recebe apenas a informação relevante (ex: as 3 notas fiscais do fornecedor X), não o banco de dados inteiro.
3. Modelo Híbrido (Otimização de Custo)	Prioriza <i>embeddings</i> locais e gratuitos (<i>Sentence Transformers</i>) para a busca (RAG).	Reserva o LLM premium (Gemini) – que é a parte cara – apenas para a tarefa de raciocínio complexo e geração da resposta final.

Esta arquitetura demonstra uma maturidade financeira e técnica notável. A decisão de usar *embeddings* gratuitos locais (documentada no [FREE_EMBEDDINGS_README.md](#)) resolve diretamente o gargalo de custo e quotas de API.

Como detalhado na apresentação, uma análise de custo determinística para 1 milhão de transações/dia com GPT-4o custaria \$6.47M anuais, enquanto com Gemini 1.5 Pro custaria \$2.56M anuais. A arquitetura híbrida desenvolvida pelo grupo reduz esses custos de forma ainda mais drástica, tornando o produto comercialmente viável para empresas de qualquer porte.

6. Conclusão: De Centro de Custo a Ativo de Inteligência Estratégica

A ferramenta demonstra com sucesso como a aplicação inteligente de Agentes de IA pode redefinir fundamentalmente uma função de *back-office* crítica, como a gestão fiscal. O projeto não se limita a automatizar tarefas manuais — o que, por si só, já representaria um ROI (Retorno sobre o Investimento) claro através da redução de OPEX (Custos Operacionais) e da eliminação de retrabalho.

A verdadeira inovação da plataforma reside em sua dupla capacidade:

- 1. Transformação de Valor:** Converte um "passivo" fiscal (um repositório de dados estáticos e de alto risco) em um ativo de inteligência de negócios (BI) dinâmico e consultável. A funcionalidade de RAG (Chat IA) desbloqueia o valor oculto nos

dados, permitindo que gestores tomem decisões estratégicas baseadas em informações que antes eram inacessíveis.

2. **Viabilidade Econômica:** O projeto prova que uma solução de IA avançada pode ser implementada de forma economicamente sustentável. A arquitetura híbrida, que prioriza *embeddings* locais gratuitos para a busca e reserva o LLM premium (Gemini) apenas para o raciocínio complexo, é uma decisão de engenharia madura e focada no negócio. Esta abordagem endereça diretamente o principal gargalo de soluções de IA em larga escala: o Custo Total de Propriedade (TCO).

Em suma, o sistema entrega uma solução completa que atende às três principais demandas do setor financeiro corporativo: reduz custos operacionais, mitiga riscos financeiros e de *compliance* e, o mais importante, gera inteligência acionável para o futuro do negócio.

7. Link para o Repositório do Projeto

O código-fonte completo, documentação técnica, *scripts* de migração e testes da plataforma SkyNET-I2A2 estão disponíveis no seguinte repositório:

Desenvolvido por: SkyNET-I2A2

Github (entrega): <https://github.com/efantinatti/SkyNET-I2A2/tree/main/Delivery/20251030>

Infográfico: http://efantinatti.github.io/SkyNET-I2A2/Final_Infografico_20251030.html

AWS' Instance App: <http://skynet-i2a2.fantinatti.net:8501>